# Motivos e perfis

## Sequência de consenso

A partir do alinhamento múltiplo de uma família de sequências é possível determinar preferências **posicionais** para a ocorrência dos 20 a.a.

Exemplo:

GHEGVGKVVKLGAGA
GHEGYGGRSRGGGYS
GHEFEGPKGCGALYI
GHELRGTTFMPALEC

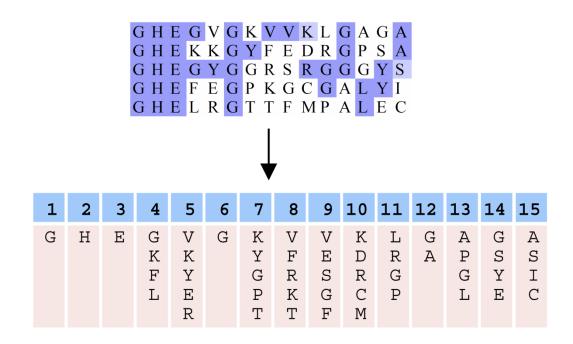
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15
GHEGYGGRSRGGGYS
GHEFEGPKGCGALYI
GHELRGTTFMPALEC

Consensus: GHE\*\*G\*\*\*\*G\*\*\*

Sequência de consenso: posições 100% conservadas no alihamento.

## Protocolo de alinhamentos múltiplos

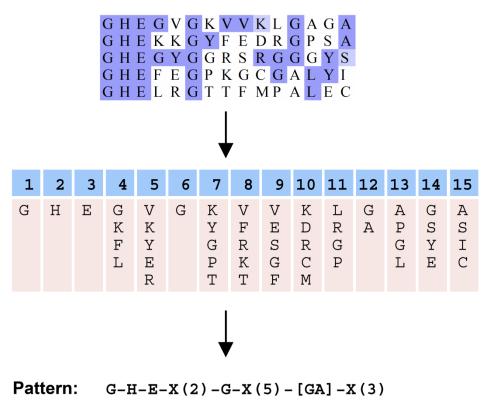
A sequência de consenso não permite descrever preferências não-integrais (<100%).



Na posição 12 podem ocorrer dois resíduos (G e A). Como representar este tipo de situação ?

## Construção de Motivos

A variedade composicional do alinhamento múltiplo pode ser descrita por um **motivo**.



O **motivo** ou padrão representa de forma simbólica as características de conservação da zona alinhada. Muitos domínios funcionais apresentam motivos (ou assinaturas) característicos.

## Formato dos padrões PROSITE

A sintaxe dos padrões PROSITE rege-se pelas seguintes regras:

- 1.Códigos IUPAC para aminóacidos (1-letter)
- 2.Os elementos são separados por "-"
- 3."X" representa qualquer aminoácido
- 4.Ambiguidades representadas por "[]" (Ex. [AG] = A ou G)
- 5. Aminoácidos proibidos entre "{}" (Ex: {AG} todos os a.a. excepto A ou G)
- 6.Repetições são representadas por "()" (Ex: X(2) dois a.a. quaisquer, [AG](2,4) A ou G de 2 a 4 vezes
- 7.Para o C- e N-term (match no início ou fim) usam-se os símbolos "<" ou ">" Exemplo:

$$G-H-E-X(2)-G-X(5)-[GA]-X(3)$$

## Exemplo de padrão PROSITE

### O seguinte padrão:

$$$$

### significa:

- 1.Uma Ala (A) no N-terminal,
- 2. Seguida de um aminoácido qualquer,
- 3. Seguida de uma Ser(S) ou Thr(T) duas vezes,
- 4. Seguida de zero ou um aminoácidos quaisquer,
- 5. Seguida de qualquer aminoácido menos Valina (V).

## **Motivos PROSITE**

Padrões PROSITE que descrevem motivos de sequência primária característicos de locais de reconhecimento ou de famílias de proteínas. Associados a aspectos **funcionais** e **estruturais**.

Exemplos (usando o formato PROSITE):

• site de fosforilação das proteínas cinases:

local de glicosilação:

• "Zipper" de leucina:

$$L-x(6)-L-x(6)-L-x(6)-L$$

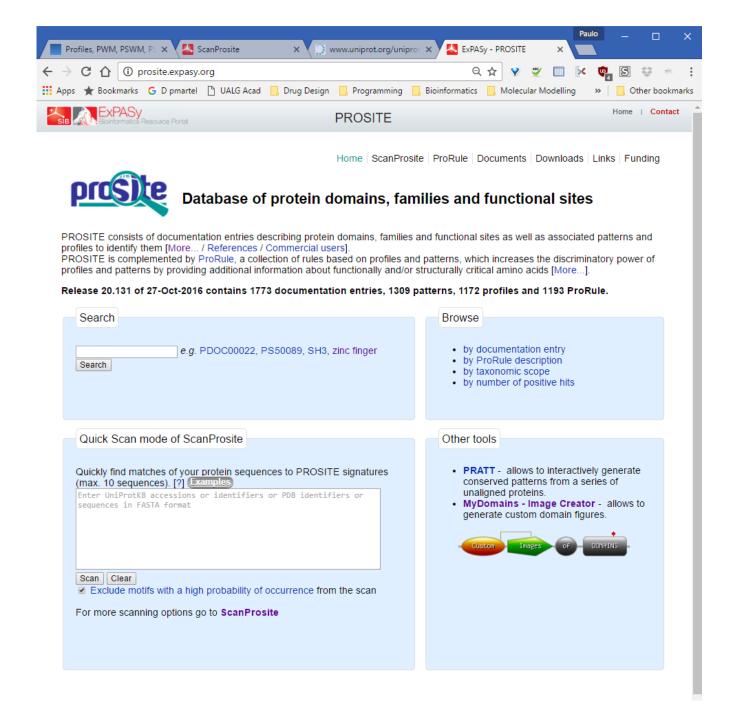
• Família das proteases de serina, histidina do centro activo: [LIVM]-[ST]-A-[STAG]-H-C

• Local de  $\gamma$ -carboxilação dependente da vitamina-K: x(12)-E-x(3)-E-x-C-x(6)-[DEN]-x-[LIVMFY]-x(9)-[FYW]



## Base de dados PROSITE

- Base de dados de famílias e domínios proteícos
- Apesar do elevado número de proteínas conhecidas, a maioria pode ser agrupada num número limitado de famílias, com base na simillaridade
- Proteínas ou domínios proteicos pertencendo a uma determinada família têm geralmente uma mesma função e um ancestral comum
- O estudo das famílias de proteínas indica que a conservação não é constante ao longo da sequência
- As zonas mais conservadas têm geralmente importância funcional
- Comparação das zonas conservadas permite derivar uma assinatura, ou motivo, que distingue os membros dessa família de outras proteínas
- PROSITE contem motivos e perfis para mais de 1000 famílias de proteínas
- Contem patterns (motivos) e profiles (perfis) que são formas diferentes de descrever assinaturas de uma sequência







Home | ScanProsite | ProRule | Documents | Downloads | Links | Funding



### Prosite search results

Search in PROSITE for: kringle

(Release 20.131, of 27-Oct-2016)

Enter search terms: kringle

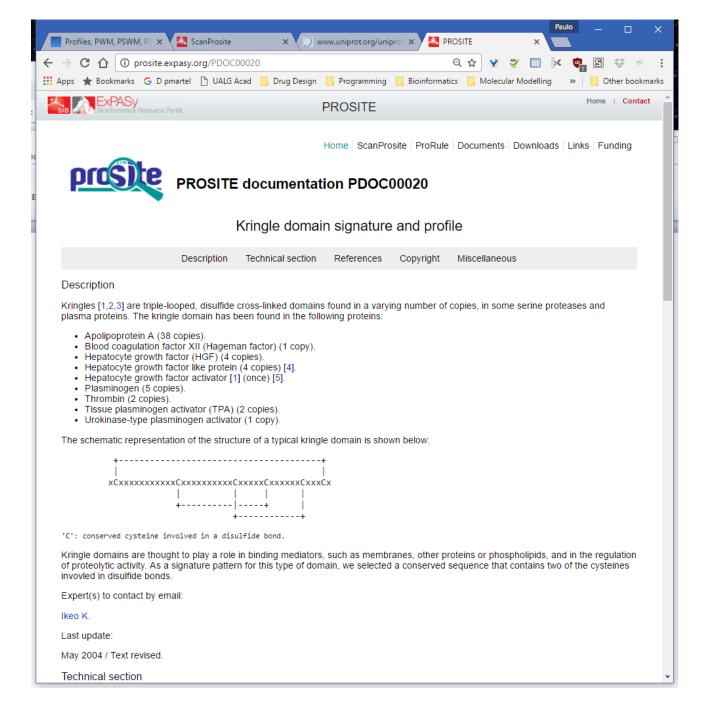
Prefix and append wildcard '\*' to words.

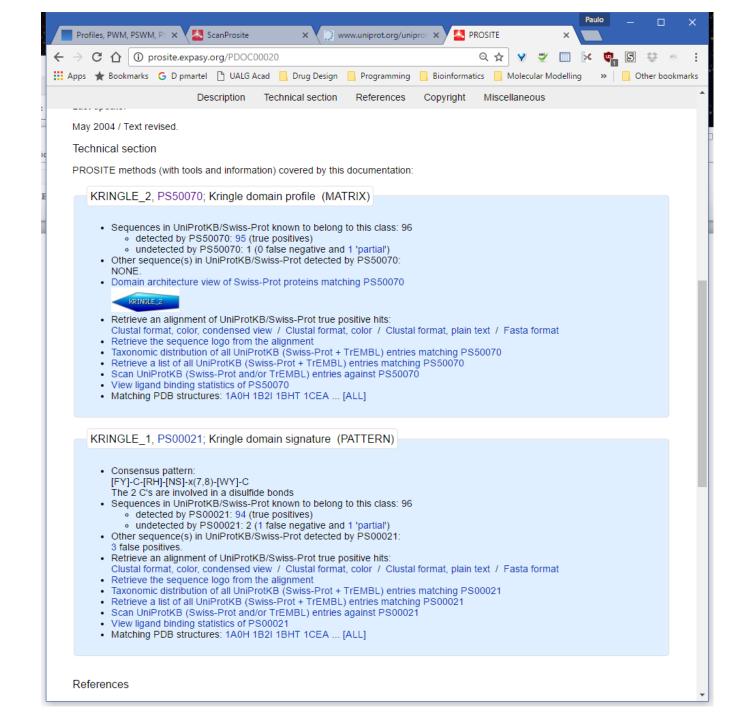
new search | clear

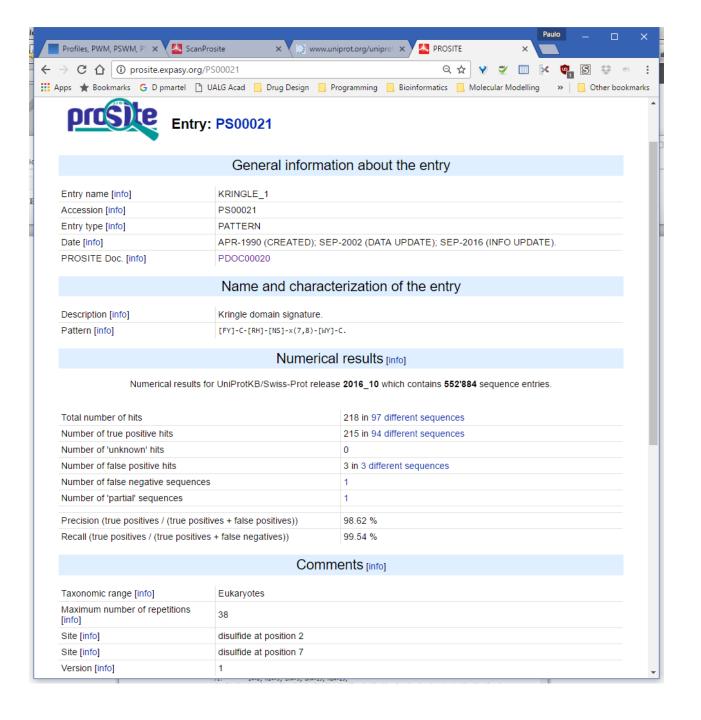
By default, this search engine searches for complete words only. If you did not find what you expected, and would try to do a substring match, you should perform a new search and select 'prefix and append wildcard to words'.

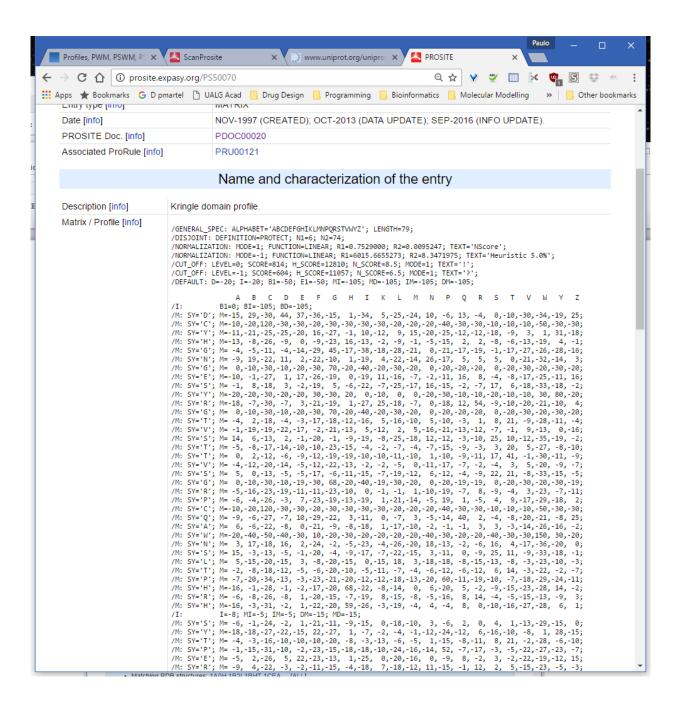
#### Number of documents in PROSITE containing the search term:4

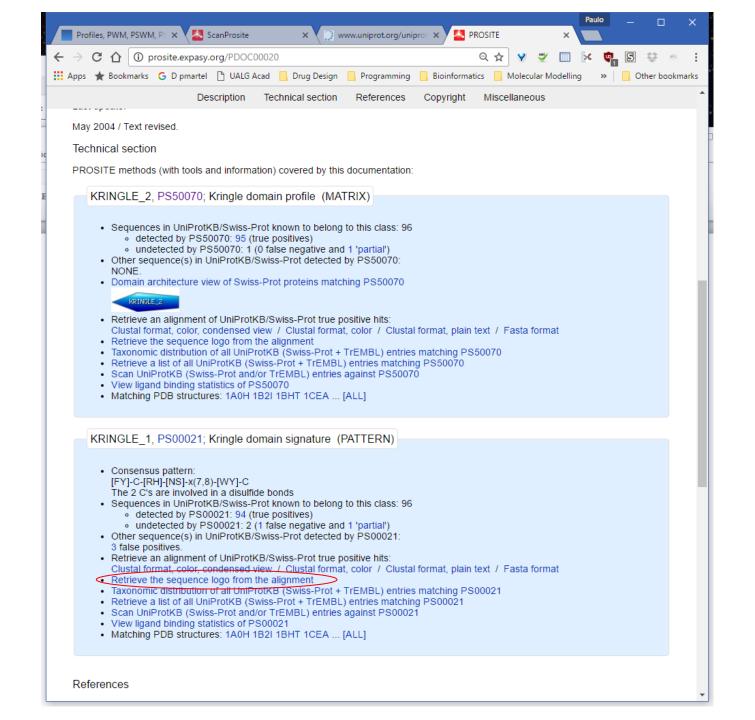
- PDOC00537 C-type lectin domain signature and profile
- PDOC00965 Fibronectin type-I domain signature and profile
- · PDOC00020 Kringle domain signature and profile
- PDOC51212 WSC domain profile

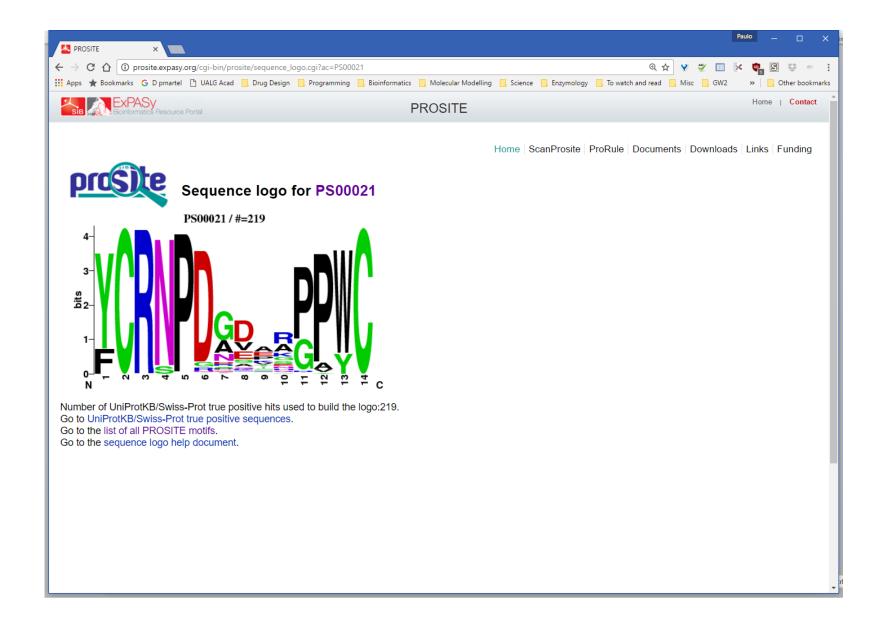




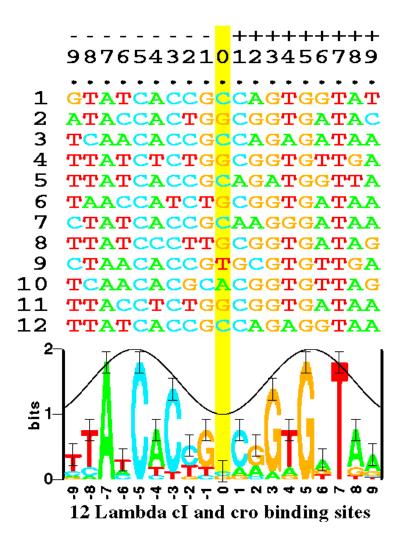




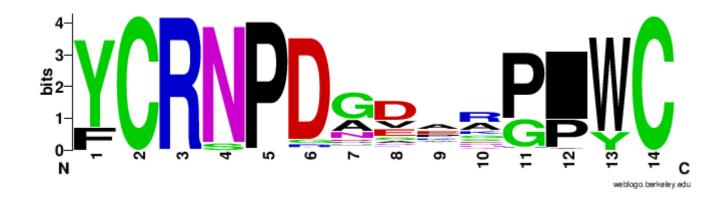




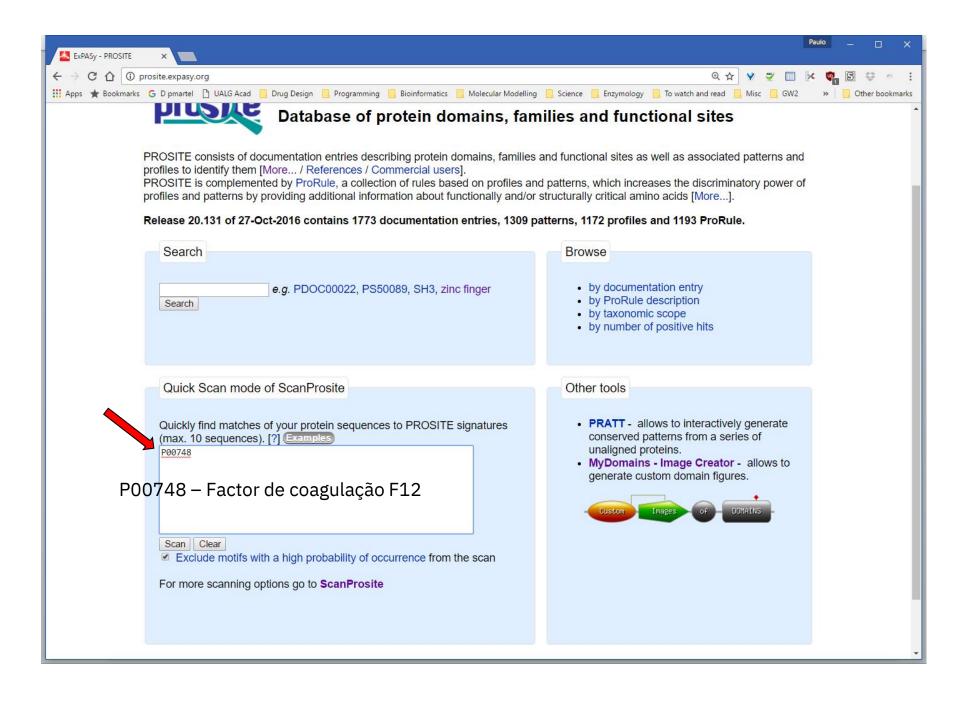
## [FY]-C-[RH]-[NS]-x(7,8)-[WY]-C

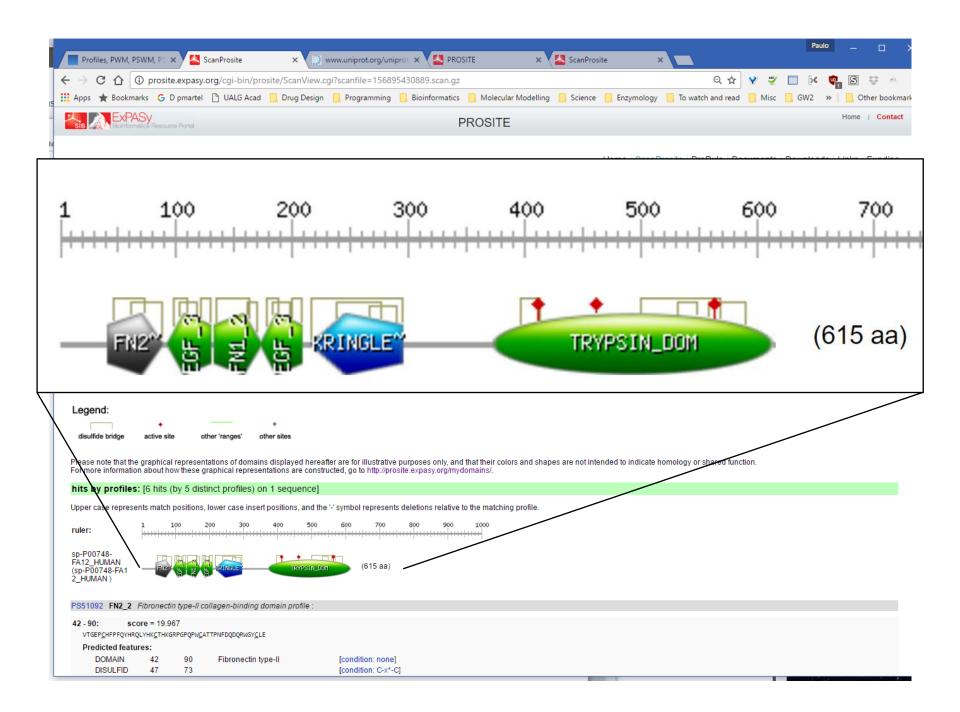


# Logo versus padrão PROSITE

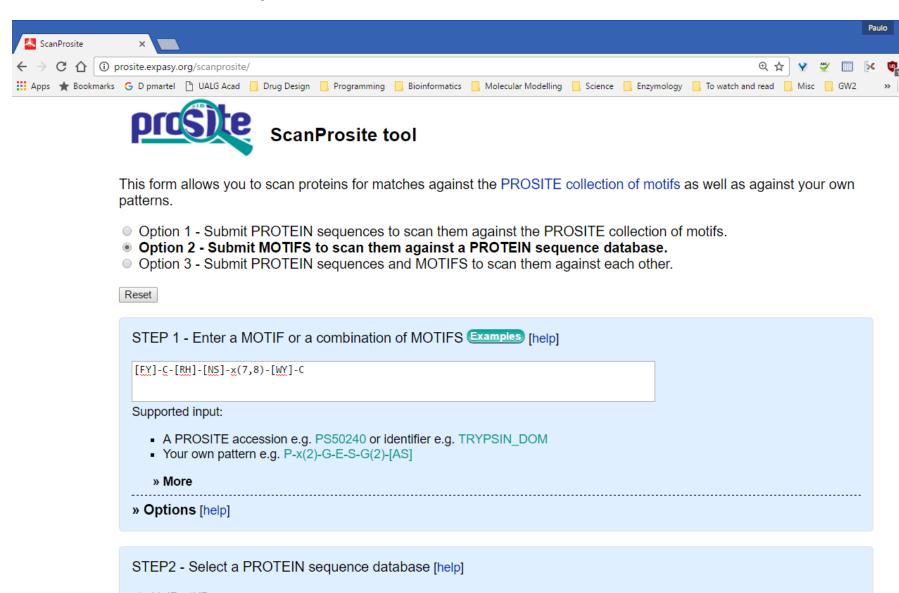


[FY]-C-[RH]-[NS]-x(7,8)-[WY]-C

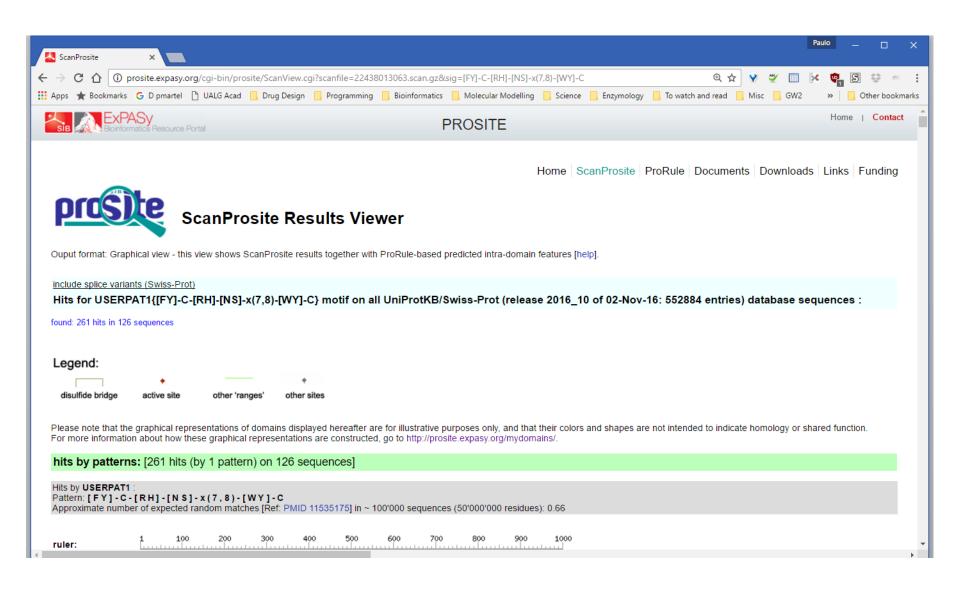


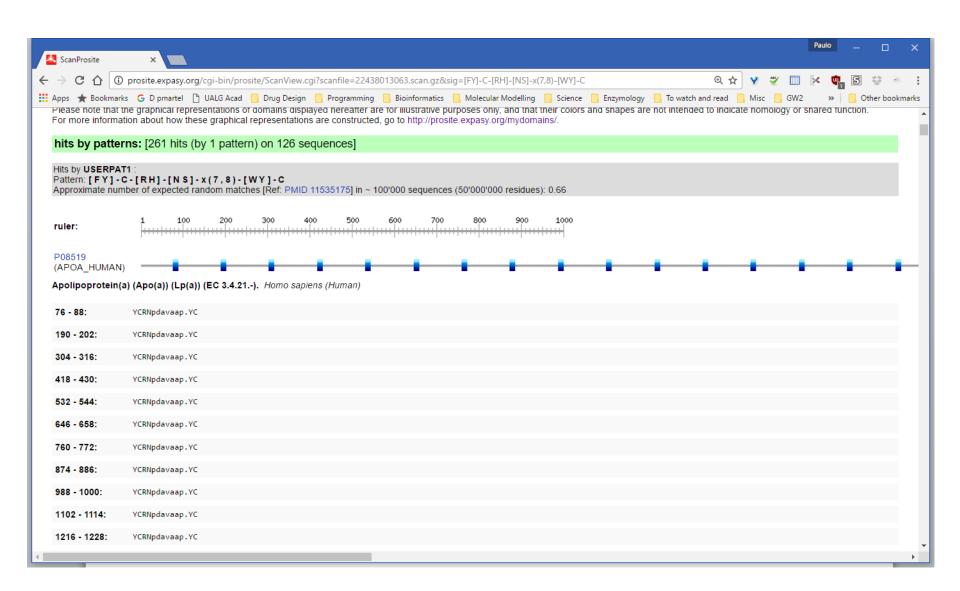


## Pesquisa de motivos com Prosite



http://prosite.expasy.org/scanprosite/





## Exemplo de entrada na base PROSITE (motivo)

```
ID CUTINASE 1; PATTERN.
AC PS00155;
DT APR-1990 (CREATED); NOV-1997 (DATA UPDATE); MAR-2005 (INFO UPDATE).
DE Cutinase, serine active site.
PA P-x-[STA]-x-[LIV]-[IVT]-x-[GS]-G-Y-S-[OL]-G.
NR /RELEASE=46.4,178022;
   /TOTAL=20(20); /POSITIVE=20(20); /UNKNOWN=0(0); /FALSE POS=0(0);
NR /FALSE NEG=0; /PARTIAL=0;
   /TAXO-RANGE=??EP?; /MAX-REPEAT=1;
   /SITE=11,active site;
DR P63880, CUT1 MYCBO , T; P63879, CUT1 MYCTU , T; P63882, CUT2 MYCBO , T;
DR P63881, CUT2 MYCTU , T; P0A537, CUT3 MYCBO , T; P0A536, CUT3 MYCTU , T;
DR P00590, CUTI1 FUSSO, T; Q96UT0, CUTI2 FUSSO, T; Q96US9, CUTI3 FUSSO, T;
    P41744, CUTI ALTBR , T; P29292, CUTI ASCRA , T; P52956, CUTI ASPOR , T;
    Q00298, CUTI BOTCI , T; P10951, CUTI COLCA , T; P11373, CUTI COLGL , T;
    Q8X1P1, CUTI ERYGR , T; Q99174, CUTI FUSSC , T; P30272, CUTI MAGGR , T;
    Q8TGB8, CUTI MONFR , T; Q9Y7G8, CUTI PYRBR , T;
    1AGY; 1CEX; 1CUA; 1CUB; 1CUC; 1CUD; 1CUE; 1CUF; 1CUG; 1CUH; 1CUS; 1CUU;
    1CUV; 1CUW; 1CUY; 1CUZ; 1FFA; 1FFB; 1FFC; 1FFD; 1FFE; 1OXM; 1XZA; 1XZB;
3D
   1XZC; 1XZD; 1XZE; 1XZF; 1XZG; 1XZH; 1XZJ; 1XZK; 1XZL; 1XZM; 2CUT;
   PDOC00140;
DO
//
```

## Exemplo de entrada na base PROSITE (perfil)

```
HSP20; MATRIX.
    PS01031;
AC
    JUN-1994 (CREATED); DEC-2001 (DATA UPDATE); MAR-2005 (INFO UPDATE).
DT
    Heat shock hsp20 proteins family profile.
DE
    /GENERAL SPEC: ALPHABET='ABCDEFGHIKLMNPQRSTVWYZ'; LENGTH=88;
MA
     /DISJOINT: DEFINITION=PROTECT; N1=6; N2=83;
     /NORMALIZATION: MODE=1; FUNCTION=LINEAR; R1=-0.7971325; R2=0.0157729; TEXT='-Loge';
MA
    /CUT OFF: LEVEL=0; SCORE=590; N SCORE=8.5; MODE=1; TEXT='!';
MA
MA
     /CUT OFF: LEVEL=-1; SCORE=463; N SCORE=6.5; MODE=1; TEXT='?';
     /DEFAULT: M0=-8; D=-20; I=-20; B1=-50; E1=-50; MI=-105; MD=-105; IM=-105; DM=-105;
    /I: B1=0; BI=-105; BD=-105;
    /M: SY='D'; M=-10,26,-29,38,34,-34,-14,-2,-33,7,-24,-23,8,-6,8,-4,0,-9,-27,-33,-19,21;
MΑ
    /M: SY='I'; M=-8,-31,-23,-35,-28,7,-32,-27,27,-24,15,13,-27,-26,-24,-23,-20,-9,25,-4,2,-27;
MA
    /M: SY='R'; M=-11,-12,-26,-12,-1,-13,-23,-1,-8,1,-7,-3,-8,-11,-2,8,-9,-6,-8,-22,-3,-4;
MA
   M: SY='E'; M=-11,17,-27,23,29,-24,-15,-3,-27,1,-22,-20,9,-1,6,-6,3,-4,-25,-32,-17,17;
MA
    /M: SY='D'; M=-7,10,-23,11,2,-25,0,-6,-26,-4,-23,-18,7,-6,-5,-8,7,7,-20,-31,-17,-2;
MA /I: I=-4; MD=-22;
MA /M: SY='D'; M=-8,17,-27,25,19,-30,-13,-5,-28,6,-25,-20,7,3,4,-1,0,-7,-24,-30,-19,10; D=-4;
MA /I: I=-4; MI=0; MD=-22; IM=0; DM=-22;
    /M: SY='D'; M=-11,20,-25,24,16,-29,-12,-1,-27,14,-25,-16,14,-9,10,5,1,-6,-23,-28,-14,13; D=-4;
MA
   /I: I=-4; DM=-22;
... Some lines omitted..
   /M: SY='K'; M=-9,-5,-25,-6,0,-22,-21,-12,-17,30,-21,-6,-3,-16,1,23,-9,-7,-6,-23,-11,0;
MA
MA /I: E1=0; IE=-105; DE=-105;
NR
   /RELEASE=46.4,178022;
    /TOTAL=195(194); /POSITIVE=190(189); /UNKNOWN=5(5); /FALSE POS=0(0);
     /FALSE NEG=1; /PARTIAL=8;
     /MATRIX TYPE=protein domain;
     /SCALING DB=reversed;
CC
CC
    /AUTHOR=P Bucher;
CC
    /TAXO-RANGE=A?EP?; /MAX-REPEAT=2;
     /FT KEY=DOMAIN; /FT DESC=HSP20;
CC
     POA5B8, 14KD MYCBO , T; POA5B7, 14KD MYCTU , T; P46729, 18K1 MYCAV , T;
     P46730, 18K1 MYCIT , T; P46731, 18K2 MYCAV , T; P46732, 18K2 MYCIT , T;
DR
     P12809, 18KD MYCLE , T; P80485, ASP1 STRTR , T; O30851, ASP2 STRTR , T;
DR
... Some lines omitted..
```

## Perfis (profiles)

Um **perfil** é uma descrição do padrão subjacente a um alinhamento múltiplo e reflecte a probabilidade de ocorrência de cada tipo de resíduo numa dada posição. Tem várias aplicações:

- Permite uma maior precisão no alinhamento de sequências distantes da mesma família
- Os padrões emergentes são úteis para a **classificação** de sub-famílias dentro de um conjunto de sequências homólogas.
- O alinhamento de uma sequência a um perfil é geralmente mais fiável e melhora o processo de **modelação estrutural** por homologia
- Os perfis permite **pesquisas de elevada sensibilidade** para a detecção de parentes distantes de uma dada família de proteínas

O alinhamento de uma sequência a um perfil é condicionado pela sua natureza e pelo seu grau de conservação. Assim, resíduos altamente conservados no perfil terão um score mais alto, e resíduos pouco conservados um score mais baixo. Este processo impõe uma tendência para alinhar em primeiro lugar as zonas mais conservadas.

# Geração de perfis a partir de alinhamentos múltiplos

```
Q3IC08|DNAK PSEHT
                      (358)
                             GKEPRKDVNPDEAVAVGAAIQGGVLAGD
Q3KIA0|DNAK PSEPF
                       358)
                             GKEARKDVNPDEAVAMGAAIQGAVLAGD
Q4ZNP7|DNAK PSEU2
                             GKEARKDVNPDEAVAMGAAIQGAVLAGD
Q4FPS9|DNAK PSYAR
Q46XI7|DNAK RALEJ
                             GKEARKDVNPDEAVAVGAAIQGSVLSGD
Q4UJK7|DNAK RICFE
                             GREPHKGVNPDEVVALGAAIQGGVLNKE
Q57TP3|DNAK SALCH
                      (358)
                             GKEPRKDVNPDEAVAIGAAVOGGVLTGD
Q5PDJ5|DNAK SALPA
                             GKEPRKDVNPDEAVAIGAAVQGGVLTGI
Q326K7 | DNAK
Q32KA5 | DNAK
                             GKEPRKDVNPDEAVAIGAAVQGGVLTGD
Q3Z601 | DNAK
Q5LWJ6|DNAK SILPO
                             GKEPHKGVNPDEVVAMGAA IQAGVLQGI
Q5HFI0|DNAK STAAC
                             GKEPNKGVNPDEVVAMGAAIQGGVITGD
Q5HNW6|DNAK STAEQ
                             GKEPHKGVNPDEVVAMGAA IQAGVITGD
Q4L6T0|DNAK STAHJ
Q49Y22|DNAK STAS1
                             GKDPHKGVNPDEVVAMGAAIOGGVITGD
POA3J3|DNAK STRA5
P0A3J4|DNAK STRAG
                      (328)
POCOC6 | DNAK STRP1
P68837|DNAK STRP8
Q48RR3 | DNAK
Q5M1T8 | DNAK STRT1
O5M6D1|DNAK STRT2
                             GKEPNKSVNPDEVVAMGAAIOGGVISGD
047TI0|DNAK THEFY
```

```
Z Gap Len
Cons A
                                                   N
                                                                      22 21 -18
                                           15 13
                                                                                        4 100 100
                      -18 19
                                                                          3
                                                           0 -10
                                                                      10 10
                                                                                           22 22
L
                      -12 29
                                                                      19
                                                                                         100 100
                                                                                         100 100
          22
                        -5 12
     8 -1 12
                                                                                       -7 100 100
C
                                                                      10 31
           15
                                                                 11
                                                                      5
                                                                         15 -22
С
                                 1 20
```



About PIR

Search/Analysis

Download

Support

### HOME / Search / Pattern Search

### http://pir.georgetown.edu/pirwww/search/pattern.shtml

Pattern Search Forms ?
Search a query pattern against a UniProt database
1. Select a database:  © UniProtKB (or restricted by organism/taxon group) © UniRef100
2. Insert a <u>user-defined pattern below:</u> $x(12)-E-x(3)-E-x-C-x(6)-[DEN]-x-[LIVMFY]-x(9)-[FYW]$
Or, alternatively, enter a valid PROSITE code for a query pattern:
Submit Reset Example: PS00888 (annotated output)
Search your query sequence against the PROSITE database
Insert a query sequence below using the single letter <u>amino acid code</u> :
Or, alternatively, enter a <u>UniProtKB identifier</u> :  Submit Reset
Example: O05689 (annotated output)



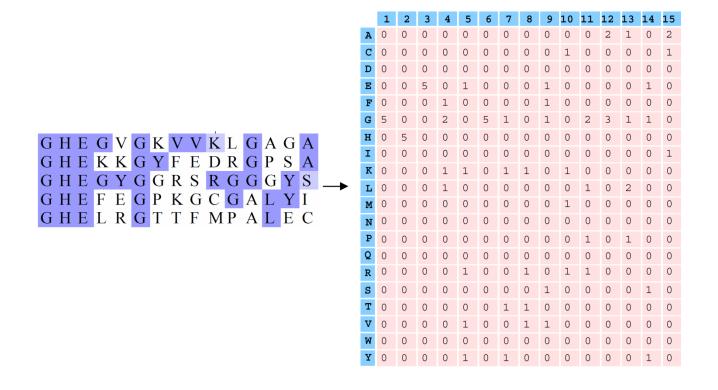
Home | About PIR | Databases | Search/Analysis | Download | Support

SITE MAP | TERMS OF USE

# **Matrizes PSSM**

- PSSM (position specific scoring matrix) é um tipo de matriz cujos scores por aminoácido são dependentes da posição do aminoácido na sequência.
- As matrizes PSSM são semelhantes a perfis e permitem armazenar informação para uma determinada assinatura ou motivo de uma família de proteínas.
- Os valores de uma matriz PSSM são calculados a partir regiões conservadas de alinhamentos de sequências.
- As matrizes PSSM permitem detectar padrões e similaridades fracas

# Criação de uma matriz PSSM



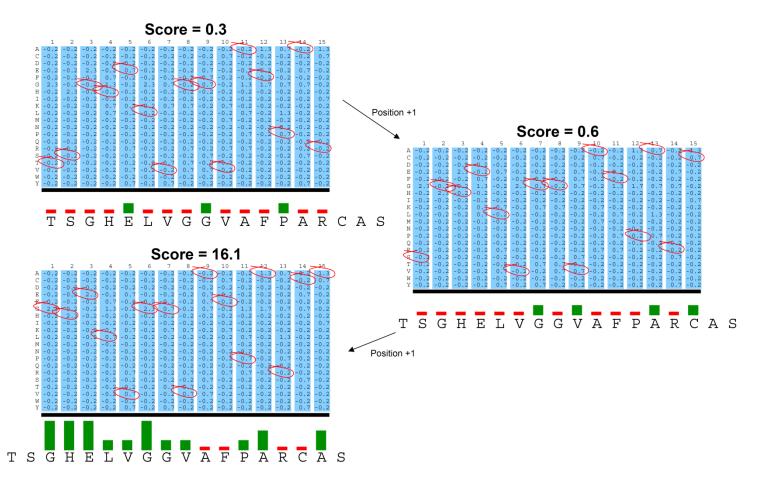
As frequências de ocorrência de cada aminoácido são contadas para cada **posição** do alinhamento. As contagens são normalizadas e convertidas numa matriz log odds semelhante a uma matriz de score.

# Criação de uma matriz PSSM

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Α	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	(1.3)	(0.7)	-0.2	0.7 -0.2
C	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	(0.7)	-0.2	-0.2	-0.2	-0.2	(0.7)
D	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2
Е	-0.2	-0.2	2.3	-0.2	(0.7)	-0.2	-0.2	-0.2	(0.7)	-0.2	-0.2	-0.2	-0.2	(0.7)	-0.2
F	-0.2	-0.2	-0.2	0.7	-0.2	-0.2	-0.2	-0.2	0.7 0.7 0.7	-0.2	-0.2	-0.2	-0.2	-02	-0.2
G	2.3	-0.2	-0.2	(1.3)	-0.2	2.3	(0.7)	-0.2	(0.7)	-0.2	(1.3)	(1.7)	-0.2 0.7 -0.2	(0.7)	-0.2
Н	-0.2	(2.3)	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2
1	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	0.7
K	-0.2	-0.2	-0.2	(0.7)	0.7	-0.2	0.7	<b>(</b> 0.7 <b>)</b>	-0.2	0.7	-0.2	-0.2	-0.2	-0.2	-0.2
L	-0.2	-0.2	-0.2	0.7	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	(0.7)	-0.2	-0.2 1.3	-0.2	-0.2
М	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	0.7	-0.2	-0.2	-0.2	-0.2	-0.2
N	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2
Р	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	(0.7)	-0.2	0.7	-0.2	-0.2
Q	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2
R	-0.2	-0.2	-0.2	-0.2	(0.7)	-0.2	-0.2	(0.7)	-0.2	(0.7)	(0.7)	-0.2	-0.2	-0.2	-0.2
S	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	(0.7)	0.7	-0.2	-0.2	-0.2	(0.7)	-0.2
Т	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	0.7	0.7	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2
V	-0.2	-0.2	-0.2	-0.2	(0.7)	-0.2	-0.2	(0.7)	(0.7)	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2
W	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2
Υ	-0.2	-0.2	-0.2	-0.2	(0.7)	-0.2	0.7	-0.2	-0.2	-0.2	-0.2	-0.2	-0.2	0.7	-0.2

Matriz PSSM calculada a partir do exemplo do slide anterior.

# Uso de matriz PSSM



A matriz PSSM "desliza" sobre a sequência em análise, produzindo um score para cada posição. O score máximo indicará a posição do padrão codificado pela matriz PSSM.

# **PSI-BLAST**

# **PSI-BLAST**

- O variant PSI do programa BLAST combina um model PSSM com uma esquema de penalidades afins para "gaps
- Princípio do algoritmo:
  - 1. Fazer uma pesquisa BLAST standard contra uma base de dados usando uma matriz de alinhamento (por exemplo BLOSUM)
  - Um modelo PSSM é construído automaticamente a partir do alinhamento múltiplo dos "hits" de score mais elevado
  - O modelo PSSM é usado em vez da matriz de score original para realizar uma nova pesquisa BLAST
  - 4. Novas sequências obtidas em 3. são usadas para construir um novo alinhamento múltiplo, e a partir destes uma nova matriz PSSM
  - 5. Os passos 3. e 4. são repetidos, sendo em cada repetição adicionadas novas sequêncais à lista de hits
  - 6. Considera-se que o algoritmo convergiu quando aparecerem sequências novas

## Bases de dados de motivos e domínios

### PROSITE

http://www.expasy.ch/prosite

### PRINTS

http://www.bioinf.man.ac.uk/dbbrowser/PRINTS

### PFAM

http://www.sanger.ac.uk/Software/Pfam

### PRODOM

http://prodom.prabi.fr

### SMART

http://smart.embl-heidelberg.de

Pesquisa em múltiplas bases de dados:

### **INTERPRO**

http://www.ebi.ac.uk/interpro