

Bioinformática

Licenciaturas em Biologia, Bioquímica e
Biotecnologia

Paulo Martel / João Varela
pmartle@ualg.pt

Docentes

- João Varela pesquisa de ORFs e suas funções, anotação de sequências, uso da ferramenta Annotathon, incluindo filogenia, construção de árvores e identificação de OTUs).
- Paulo Martel (bioinformática: conceitos, bases de dados, aplicações. Comparação e alinhamento de pares de sequências, algoritmos de alinhamento, pesquisas de sequências homólogas em base de dados, bioinformática estrutural)

Competências

- Conceito de ORF, pesquisa de ORFs em sequências nucleotídicas (JV)
- Previsão da localização de genes em genomas e metagenomas (JV)
- Bioinformática aplicada à taxonomia molecular (JV)
- Estimação de massa molecular de proteínas e ácidos nucleicos (JV)
- Alinhamentos de sequências: ferramentas e aplicações (PM)
- Construção de árvores filogenéticas: modelos, ferramentas e aplicações (JV)
- Previsão da função de genes e/ou proteínas por pesquisa de domínios funcionais (JV)
- Previsão da estrutura de proteínas; previsão da função e compreensão dos mecanismos de acção de proteínas através da bioinformática estrutural (JV e PM)
- Anotação de sequências de bases de dados via Annotathon (JV)

Avaliação - Bioinformática

- **Exame teórico** – JV 50%, PM 50%
- **Componente Prática** - Anotação de 1 sequência metagenômica (Annotathon) – não há grupos; exame prático na Época de Recorrência caso haja reprovação
- $NOTA\ FINAL = 70\% \text{ Teórica} + 30\% \text{ Prática}$

Bibliografia

- Choudhuri, Supratim, and Michael Kotewicz. *Bioinformatics for Beginners: Genes, Genomes, Molecular Evolution, Databases, and Analytical Tools*. Elsevier/AP, 2014.
- Claverie, Jean-Michel, and Cedric Notredame. *Bioinformatics for Dummies*. 2nd ed, Wiley Pub, 2007.
- Lesk, Arthur M. *Introduction to Bioinformatics*. Fifth edition, Oxford University Press, 2019.
- Mount, David W. *Bioinformatics: Sequence and Genome Analysis*. 2nd ed, Cold Spring Harbor Laboratory Press, 2004.

Bioinformática: o que é ?

O termo “bioinformática” foi utilizado pela primeira vez em 1970 por **Pauline Hog** e **Ben Hesper**, mas o seu significado alterou-se um pouco ao longo do tempo, não existindo uma definição universalmente aceite.

“Bioinformatics is conceptualizing biology in terms of molecules (in the sense of physical-chemistry) and then applying “informatics” techniques (derived from disciplines such as applied math, CS, and statistics) to understand and organize the information associated with these molecules, on a large-scale.”

“(1) Bioinformatics is the development of computational methods for studying the structure, function, and evolution of genes, proteins and whole genomes.

(2) bioinformatics is the development of methods for the management and analysis of biological information arising from genomics and high throughput experiments.”

Hesper B, Hogeweg P. Bioinformatica: een werkconcept. *Kameleon*. 1970;1(6):28-29

Bioinformática: Conceito

Bioinformática - campo interdisciplinar da Biologia, Ciências Informáticas, Matemática e Estatística para analisar dados de sequências biológicas e genomas (genes e disposição de genes em cromossomas) e prever a estrutura e função de macromoléculas


Bioinformática vs. Biologia Computacional

- **Bioinformática** – aplicação de ferramentas computacionais à análise e processamento de dados biológicos, geralmente de grande volume.
- **Biologia Computacional** – desenvolvimento mais genérico de **algoritmos computacionais** capazes de resolver uma variedade de problema biológicos incluindo (mas não só), algoritmos bioinformáticos como o alinhamento, pesquisa de sequências, comparação de estruturas, identificação de motivos, filogenia molecular, etc.

Algoritmo

Conjunto de instruções bem definidas para resolver um problema; quando aplicado em informática, um algoritmo pode ser transformado em um programa e este numa aplicação informática.

Algoritmo representado por um diagrama de fluxo




Bioinformática: para que serve?

Limitação da mente humana em [armazenar](#) e [processar](#) informação devido a:

- Complexidade dos genomas
- N° crescente de genomas sequenciados
- N° crescente de anotações estruturais, funcionais e bibliográficas
- N° crescente de estruturas de proteínas

Explosão de Sequenciação-1




Número total de sequências nos bancos de dados NCBI GenBank e WGS (Whole Genome Shotgun) databases ao longo do tempo.


Explosão de Sequenciação-2

Adapted from
The Economist

The Sequencing Explosion



Sequencição de Nova Geração



Como resolver esta limitação humana?

- Aplicações computadorizadas de **armazenamento** de dados: **bases de dados**
- Aplicações computadorizadas de **processamento** de dados

Exemplo de Bases de Dados

(sequências primárias de ácidos nucleicos e proteína com anotação básica)

- GenBank (NCBI, EUA)
<http://www.ncbi.nlm.nih.gov/gquery/gquery.fcgi>
- EMBL Nucleotide Sequence Database (Europa) <http://www.ebi.ac.uk/embl/>
- DNA Data Bank of Japan (DDBJ, Japão)
<http://www.ddbj.nig.ac.jp/>

Tipo de dados armazenados

- Sequências de DNA (desoxinucleótidos)
- Sequências de RNA (nucleótidos)
- Sequências de Proteína (aminoácidos)
- Anotações estruturais
- Anotações funcionais
- Anotações de localização intracelular
- Anotações de localização genómica
- Anotações bibliográficas


Exemplo de Bases de Dados

(sequências primárias de ácidos nucleicos e proteína com anotação mais complexa)

- Ensembl (**Genomas de vertebrados**)
<https://www.ensembl.org/>
- Ensembl (**Genomas Bacterianos**)
<https://bacteria.ensembl.org/>
- UniProtKB/Swiss-Prot (**Proteínas**)
<https://www.uniprot.org>

Exemplo de um gene anotado

(anotações do gene *BRCA* humano na plataforma Ensembl)



Exemplo de Bases de Dados

(estruturas secundárias de proteínas - domínios funcionais)


- InterPro

<https://www.ebi.ac.uk/interpro/>

- ScanProsite

<https://prosite.expasy.org/scanprosite/>

Estrutura Secundária e Domínios Funcionais



Domínios Funcionais Anotados

(Ex: InterProScan – Anotações estruturais e funcionais)

NP_000609.1

Length 153 amino acids


Protein family membership

- Insulin family (IPR022352)
- Insulin-like growth factor (IPR022350)
- Insulin-like growth factor I (IPR022341)

Homologous superfamilies




Domains and repeats



Detailed signature matches



Other features



GO Term prediction

Biological process
None predicted.

Molecular function
GO:0005179 hormone activity
GO:0008083 growth factor activity


Cellular component
GO:0005376 extracellular region
GO:0005615 extracellular space

Como funciona a bioinformática em termos práticos?

- 1. Recolha de amostras (laboratoriais, ambientais)
- 2. Isolamento de DNA (ou RNA) [por vezes opcional]
- 3. Amplificação de sequências de DNA (ou cDNA) por PCR [opcional]
- 4. Sequenciação de DNA
- 5. Armazenamento da sequência em ficheiros informáticos
- 6. Tratamento bioinformático das sequências

Recolha de Amostras Ambientais

Annothaton: Amostras de água do mar



Recolha de Amostras Ambientais

Annothaton: Amostras de água do mar (<http://annotathon.org/>)



Preparação para a aula teórico-prática

- Ir ao site ANNOTHATON
<http://annotathon.org/>
- Leiam a página “[Rule Book](#)” para ver o que tem que fazer nas aulas teórico-práticas

Como funciona a bioinformática em termos práticos?


1. Recolha de amostras (laboratoriais, ambientais)
 2. Isolamento de DNA (ou RNA) [por vezes opcional]
 3. Amplificação de sequências de DNA (ou cDNA) por PCR [opcional]
- Genética Molecular**
4. Sequenciação
 5. Armazenamento da sequência em ficheiros informáticos
 6. Tratamento bioinformático das sequências

Como funciona a bioinformática em termos práticos?

1. Recolha de amostras (laboratoriais, ambientais)
2. Isolamento de DNA (ou RNA) [por vezes opcional]
3. Amplificação de sequências de DNA (ou cDNA) por PCR [opcional]
- 4. Sequenciação de DNA
5. Armazenamento da sequência em ficheiros informáticos
6. Tratamento bioinformático das sequências

Sequenciação de DNA

O Método de Sanger baseia-se no uso de desoxinucleótidos **artificiais** em reacções de síntese de DNA (polimerização).



Desoxinucleótidos vs. Didesoxinucleótidos

Sequencição de DNA

Os dideoxynucleótidos bloqueiam a polimerização

DNA Polymerase reads the template strand and synthesizes a new second strand to match:





IF 5% of the T nucleotides are actually dideoxy T, then each strand will terminate when it gets a ddT on its growing end:

5' - TACGCGGTACGGTATGTTTCGACCGTTTAGCTACCGAT•
5' - TACGCGGTACGGTATGTTTCGACCGTTTAGCT•
5' - TACGCGGTACGGTATGTTTCGACCGTTT•
5' - TACGCGGTACGGTATGTTTCGACCGTT•
5' - TACGCGGTACGGTATGTTTCGACCGT•
5' - TACGCGGTACGGTATGTT•
5' - TACGCGGTACGGTATGT•
5' - TACGCGGTACGGTAT•
5' - TACGCGGTACGGT•
5' - TACGCGGT•

Ex: Uso de ddTTP para gerar fragmentos de diferente tamanho terminando na posição das T

Sequencição de DNA



Como funciona a bioinformática em termos práticos?

1. Recolha de amostras (laboratoriais, ambientais)
2. Isolamento de DNA (ou RNA) [por vezes opcional]
3. Amplificação de sequências de DNA (ou cDNA) por PCR [opcional]
4. Sequenciação de DNA
- 5. Armazenamento da sequência em ficheiros informáticos
6. Tratamento bioinformático das sequências

Ficheiros Bioinformáticos

- Ficheiros de texto
- Ficheiros de DNA contêm letras que representam desoxinucleótidos
- Ficheiros de Proteína contêm letras que correspondem a aminoácidos
- Podem conter também notas explicativas sobre a sequência que se denominam: ANOTAÇÕES

Códigos de representação de sequências nucleotídicas em ficheiros bioinformáticos

Table 1: List of Nucleotides

Symbol	Meaning	Origin of designation
a	a	<u>a</u> denine
g	g	<u>g</u> uanine
c	c	<u>c</u> ytosine
t	t	<u>t</u> hymine
u	u	<u>u</u> racil
r	g or a	<u>p</u> urine
y	t/u or c	<u>p</u> yrimidine
m	a or c	<u>a</u> mino
k	g or t/u	<u>k</u> eto
s	g or c	<u>s</u> trong interactions 3H-bonds
w	a or t/u	<u>w</u> weak interactions 2H-bonds
b	g or c or t/u	not a
d	a or g or t/u	not c
h	a or c or t/u	not g
v	a or g or c	not t, not u
n	a or g or c or t/u, unknown, or other	<u>a</u> ny

Códigos de representação de sequências proteicas em ficheiros bioinformáticos

One-letter symbol	Three-letter symbol	Amino acid
A	Ala	alanine
B	Asx	aspartic acid or asparagine
C	Cys	cysteine
D	Asp	aspartic acid
E	Glu	glutamic acid
F	Phe	phenylalanine
G	Gly	glycine
H	His	histidine
I	Ile	isoleucine
K	Lys	lysine
L	Leu	leucine
M	Met	methionine

One-letter symbol	Three-letter symbol	Amino acid
N	Asn	asparagine
P	Pro	proline
Q	Gln	glutamine
R	Arg	arginine
S	Ser	serine
T	Thr	threonine
U*	Sec	selenocysteine
V	Val	valine
W	Trp	tryptophan
X**	Xaa	unknown or 'other' amino acid
Y	Tyr	tyrosine
Z	Glx	glutamic acid or glutamine (or substances such as 4-carboxyglutamic acid and 5-oxoproline that yield glutamic acid on acid hydrolysis of peptides)

Formato de ficheiros de sequências nucleotídicas e a.a.

- • FASTA
- FASTA-PEARSON
 - NBRF
 - GCG
 - PIR
 - GenBank
 - PHYLIP
 - ASN.1
 - PAUP

Formato FASTA

Ficheiro de texto (ASCII) com:

- Linha de comentário iniciada por “>”
- Sequência (nucleotídica ou proteica)
- Terminação da sequência por “*” (opcional)

Exemplo:

```
> YCZ2_Yeast protein in HMR 3' region  
MKAVVIEDGKAVVKEVGP*
```

Formato de ficheiros de sequências

- FASTA
- FASTA-PEARSON
- NBRF
- GCG
- PIR
- • GenBank
- PHYLIP
- ASN.1
- PAUP

Formato GenBank

Ficheiro de texto com:

- Cabeçalho (*header*)
- Anotações (*features*)
- Sequência

Formato GenBank: Cabeçalho

Header

RefSeq Id
↓

LOCUS	NC_000854	1669695 bp	DNA	circular	BCT 03-DEC-2005
DEFINITION	Aeropyrum pernix K1, complete genome.				
ACCESSION	NC_000854				
VERSION	NC_000854.1 GI:14600379				
KEYWORDS	.				
SOURCE	Aeropyrum pernix K1 K1				
ORGANISM	Aeropyrum pernix Archaea; Crenarchaeota; Thermoprotei; Desulfurococcales; Desulfurococcaceae; Aeropyrum.				
REFERENCE	1				
AUTHORS	Kawarabayasi, Y., Hino, Y., Horikawa, H., Yamazaki, S., Haikawa, Y., Jin-no, K., Takahashi, M., Sekine, M., Baba, S., Ankai, A., Kosugi, H., Hosoyama, A., Fukui, S., Nagai, Y., Nishijima, K., Nakazawa, H., Takamiya, M., Masuda, S., Funahashi, T., Tanaka, T., Kudoh, Y., Yamazaki, J., Kushida, N., Oguchi, A., Aoki, K., Kubota, K., Nakamura, Y., Nomura, N., Sako, Y. and Kikuchi, H.				
TITLE	Complete genome sequence of an aerobic hyper-thermophilic crenarchaeon, Aeropyrum pernix K1				
JOURNAL	DNA Res. 6 (2), 83-101 (1999) PUBMED 10382966				
REFERENCE	2 (bases 1 to 1669695)				
AUTHORS	Direct Submission				
TITLE	Submitted (05-JUL-2001) National Center for Biotechnology Information, NIH, Bethesda, MD 20894, USA				
JOURNAL	3 (bases 1 to 1669695)				
REFERENCE	Tanaka, T., Hino, Y., Kawarabayasi, Y. and Kikuchi, H.				
AUTHORS	Direct Submission				
TITLE	Submitted (14-DEC-1998) National Institute of Technology and Evaluation, Biotechnology Center, 2-49-10 Nishihara, Shibuyaku, Tokyo 151-0066, Japan				
JOURNAL	COMPLETENESS: full length.				
COMMENT	PROVISIONAL REFSEQ: This record has not yet been subject to final NCBI review. The reference sequence was derived from BA000002.				

Formato GenBank: Anotações

Features	FEATURES	Location/Qualifiers
	source	1..1669695 /mol_type="genomic DNA" /db_xref="taxon:272557" /organism="Aeropyrum pernix K1"
	gene	complement(213..938) <u>/locus_tag="APE0001"</u> ← Locus tag /db_xref="GeneID:1445602"
	CDS	complement(213..938) /locus_tag="APE0001" /protein_id="NP_146894.1" /transl_table=11 /db_xref="GI:14600380" /db_xref="GeneID:1445602" /codon_start=1 /product="hypothetical protein" /translation="MVDILSSLLSLPFGVIGFLLVLSPGSIWTPVKESIGYVYVSR VTVKASKLLGSLTLLASLISFVGAAYGITIQA SLNQPVLLEGFEPVSGSIKLYLTILLVYLISIVFSIEGSLKLYSIGAYGTLASHLSIE ILAGYTVFLSVKRPEAYVIPGLSRETIELLQFFMPTSLSLIAIGVYMLAGFHMWWII LLAGVTTLFVVTMLIMINKEGKY"
	gene	complement(938..1276) /locus_tag="APE0002" /db_xref="GeneID:1445577"
	CDS	complement(938..1276) <u>/locus_tag="APE0002"</u> ← Locus tag /protein_id="NP_146895.1" /transl_table=11 /note="similar to PIR:C69525 percent identity:39.583 in 96aa." /db_xref="GI:14600381" /db_xref="GeneID:1445577" /codon_start=1 /product="hypothetical protein" /translation="MDPADKLMKDARTGVLALAVLHVLVNHGALHGYWLRKILGNLMG WTPPETSLYDALKRLEKLGLIKGRWVRSGRGPLRKYYEITDAGRETYEVVVKDFSKMV GWLICRKGRE"
	misc_feature	complement(1001..>1180) /locus_tag="APE0002" /db_xref="CDD:43477" /note="Transcriptional regulator PadR-like family; Region: PadR"

Formato GenBank: Sequência

Sequence

BASE COUNT 360022 a 473378 c 466849 g 369446 t

ORIGIN

```
1 aaataaat aaaaattaag tgactcatgc attatcctac gaggtataaa tatgttataa
61 attgtcccg actaccatca atttagggac aatagtgttt aagggatggc ctcggagct
121 ggcagctcgc gggttcaaac tcgcgtaggg cccgagttct agttatagtt gctgggattt
181 agataaaatt agtatgatct ctacgtttta tatcaatact tacctctttt attaatcata
241 attaacattg ttacaacgaa tagagtggtc actcccgcca acaggattat ccaccacata
301 tggaaatcctg ctaaaatcat atatacacct atagctatga gagataagga ggttggcatg
361 aaaaattgta atagctcgat cgtttccgca cttagtcctg gtattacata tgcctccggc
421 ctttttacag atagaaaaac ggtatatcct gctaataatt caatagataa atgtgaagct
481 aacgttccgt atgcaccaat actatatagt ttaagagAAC cttcaattga gaatacaatc
541 gagattagat aaactagtaa tataatagtc aaatatttta atttaataga acctactggc
601 tcgaatcctt caaggactgg ttggttttaa gactctattt cggcgagcct catagaatat
661 tcacacgtaa ctacggttat caatgcgaagt aatagggcta gtgtagatgc ctgaatagta
721 ataccatatg ctgcaccaac cacaaaagat attaaactcg ctaacaaagt aagcgaaccc
781 aatagcttgc tcgctttaac cgtgacgcgc ctagaacat aaacatagcc tatgctctcc
841 ttacagggc tccatattga cccaggagac aataccaaga gaaatccaat tacaccaaat
901 ggaagcgaca gcaggagtga agatagtata tctaccattt cttctcccc ttctcgaaa
961 taagccagcc aacctctttt gagaatcct ttactacaac ctcatatgtc tctctaccag
1021 catcggttat ttcatagtat ttctttaaag gccccctacc gtcctaaccc catcggccct
1081 ttattagccc cagcttttct aacctcttca aagcatcata aagactcgtc tctggaggcg
1141 tccatcccat tagattgcc aagaattttcc tcaaccaata cccatgtaga gctccatgat
1201 tgacaagtac gtgtaact gccaatgcaa gcacaccagt ccttgcctcc ttcacagct
1261 tatctgctgg atccacgtga ccccaccat ttattaggga agcctactat tagcatggag
1321 accacgacag agataccggc tggaggggca acaagcctgt taccgatagt tagggctgca
1381 aaaactcctc caataccatt aaccgttcca tgcgctattg ctggagtaat gatggagttt
1441 gaatgtctcc taagaggtaa aaggatgctt gtaaatgcta tgggtgataa tgtgaagact
1501 actatagcgg gccaccctcg ggaatagctt ccacaatctc ctagcataga tacgttgtaa
1561 ttataaccag cataaattaa gggagcatgc cagacactcc agataagacc tataataatg
1621 accttaccca gatcgtaa tttcttatcg agtatggtga agagatatcc tctccagccg
1681 agttcttctc caagtgaac aagtgcgttc atggttaactc ctgctataag accaagtaat
1741 attagtatta taaccgttgt aattagcaga gtagtattag atacctctt gaagtatccg
1801 catgggtccaa tactaacgcc taaagcctta gcgatttgta atgacatcac atatgaggct
1861 aatggcgcta ccgctgataa tatgttccat ttcaaggatg gaattataat tctcaagatt
1921 tcttttattt tctccatgtt acgatatcct tcgacccata aggctgcat aacgcctgta
1981 gcaggtagcc acatcctaaa taggaggacg atcgtgagga ggagtttatt tcggggtaag
2041 gttgtgggtg gctcttgcat tgacgttagt aactttatgg ctattgtata gtctaggagg
2101 tatgctggga cgaatgatac tgttaggaag actgctaaac ctatgtaatg gctgttatcg
2161 atttctatac gcatactacg tccacggggg tatttatcat gttatagatg tatttaagac
2221 caaagctgat ttaagaacct aacattgtat atatagtttg gtgttacctg tggcgttaga
2281 gcaattaacg attgctggaa cggagctact aaaaacatgag ctaacaagca agctagtatt
2341 cggcgtatta ttgtccgttt ggatagtc atgttcagtc atcaagctca ggaagactc
2401 gaggaatagg cagatagtcg gtctaattgt agcggctgta gccacagtcg tggcttagg
2461 tacaatagcc tatatatta acccgctcca aacctatggc gcttatctcg agagtagaac
2521 attacaaatt agattctaca tgaatgatga agtggctgtt gacttatgta acgctcagtt
2581 gtcatctgta tcgaggagca acgcaataaa cttactctac attagaacta acggatttgc
2641 tgatcctttc tcaggtaata ctgcccggata ttacaaaact gtggatgaac ggggaagccta
2701 tgtacttatc gctggttaagg acattgatga tgccttgcata atcgaaattcg acagtaaaat
2761 tatcctccta ggacttaaa gaggcaatga cttttaccaa aaactcataa tttaaaaaag
```

Como funciona a bioinformática em termos práticos?

1. Recolha de amostras (laboratoriais, ambientais)
2. Isolamento de DNA (ou RNA) [por vezes opcional]
3. Amplificação de sequências de DNA (ou cDNA) por PCR [opcional]
4. Sequenciação de DNA
5. Armazenamento da sequência em ficheiros informáticos
- 6. Tratamento bioinformático das sequências ([anotações](#))

Tradução virtual de sequências nucleotídicas em proteicas

quadro de leitura aberto (*open reading frame* [ORF])

5' 3'

atgcccaagctgaatagcgtagaggggttttcatcatttgaggacgatgtataa

Quadros de leitura (reading frames)

+1	atg	ccc	aag	ctg	aat	agc	gta	gag	ggg	ttt	tca	tca	ttt	gag	gac	gat	gta	taa
	M	P	K	L	N	S	V	E	G	F	S	S	F	E	D	D	V	*
+2	tgc	cca	agc	tga	ata	gcg	tag	agg	ggt	ttt	cat	cat	ttg	agg	acg	atg	tat	
	C	P	S	*	I	A	*	R	G	F	H	H	L	R	T	M	Y	
+3	gcc	caa	gct	gaa	tag	cgt	aga	ggg	gtt	ttc	atc	att	tga	gga	cga	tgt	ata	
	A	Q	A	E	*	R	R	G	V	F	I	I	*	G	R	C	I	

Genômica vs. Metagenômica

